

Reprezentare Eficientă pentru Explicit MPC folosind Rețele Neuronale Artificiale

Robust Tube-MPC cu Garanții de Invarianță — Aplicație: Pendulul Invers

Lungulescu Raul-Adrian

Coordonatori: Assist. Prof. Daniel Ioan

Prof. Florin Stoican

București, 2026



- 1 Introducere
- 2 Preliminarii
- 3 Învăţare Profundă bazată pe Explicit MPC cu Garanţii de Robusteţe
- 4 Simulare Numerică
- 5 Validare Experimentală
- 6 Concluzii şi Direcţii Viitoare

Scopul lucrării

Aproximarea legii de control eMPC printr-o rețea neuronală **ReLU**, încadrată într-o schemă **Robust Tube-MPC** cu garanții robuste formale, pentru implementare în timp real pe sisteme *embedded*.

MPC Clasic


- QP rezolvat **online**, la fiecare pas
- Cost computațional ridicat
- Dificil de implementat *embedded*

Explicit MPC

- Legea de control e **afină pe porțiuni (PWA)**
- Efort de calcul mutat **offline**
- Online: doar **căutare prin regiuni** (legea PWA)

Dezavantaj major eMPC

Numărul de regiuni poliedrale **explodează exponențial** cu orizontul N și numărul de constrângeri
⇒ Memorie și timpi de execuție mari ⇒ **neimplementabil** pe sisteme *embedded*.



Etapele


$$x_{k+1} = Ax_k + Bu_k + w_k, \quad \|w_k\|_{\infty} \leq w_{\text{bound}}$$

- Sistem liniarizat, stabilizare spre origine sub perturbații w
- Rețea ReLU $\approx$ legea eMPC
- Respectarea strictă a spațiilor $\mathcal{X}, \mathcal{U}$ (constrângeri)
- Garanții de stabilitate prin **tub robust**
- Implementare *embedded*, cu **timp redus** de execuție

Soluția Propusă

O rețea neuronală **ReLU** aproximează legea PWA a eMPC, încadrată într-o schemă **Robust Tube-MPC** care garantează invarianța față de **perturbațiile totale** ce afectează sistemul.

Modelul Sistemului: Pendul Invers



Detalii sistem

- **starea:** $\mathbf{x}_k = [x, \dot{x}, \theta, \dot{\theta}]^T$
- **comanda:** $u_k = F$ [N]
- **parametrii:** $m_p=0.135$ kg, $m_c=0.5$ kg, $\ell=0.23$ m, $I=\frac{4}{3}m_p\ell^2$

Ec. neliniare (Euler–Lagrange), $\delta = m_p\ell^2 + I$

$$(m_c + m_p)\ddot{x} + m_p\ell\ddot{\theta}\cos\theta - m_p\ell\dot{\theta}^2\sin\theta = F$$

$$\delta\ddot{\theta} + m_p\ell\ddot{x}\cos\theta - m_p g\ell\sin\theta = 0$$

Liniarizarea sistemului cu discretizare ($T_s = 0.02$ s, ZOH)

Aproximări unghi mic (0° – 20°): $\cos\theta \approx 1$, $\sin\theta \approx \theta$, $\dot{\theta}^2 \approx 0$, $b=0$, $k=0$

$$A_c = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & \frac{m_p g \ell}{\delta} & 0 \end{bmatrix}, \quad B_c = \begin{bmatrix} 0 \\ 1 \\ 0 \\ -\frac{m_p \ell}{\delta} \end{bmatrix} \Rightarrow \mathbf{x}_{k+1} = A\mathbf{x}_k + B u_k$$


Sistem Neliniar pentru simulare

- validare: **model neliniar**, Runge–Kutta 4 (CasADi)
- MPC, eMPC, NN: proiectate liniar, testate pe dinamica **reală** (ESP32)

Problema de optimizare cu constrângeri

$$\min_{u_N} J = \sum_{k=0}^{N-1} (x_k^\top Q x_k + u_k^\top R u_k) + x_N^\top P x_N, \quad \text{s.t. } x_{k+1} = A x_k + B u_k, \quad x_k \in \mathcal{X}, \quad u_k \in \mathcal{U}, \quad x_N \in \mathcal{X}_f$$

- $P \succ 0$: soluția DARE pentru (A, B) , ponderi (Q, R) - garantează invarianța setului terminal $\mathcal{X}_f$



mp-QP $\rightarrow$ Legea PWA

- problema QP reformulată parametric în x_0 (forma lifted)
- soluție KKT¹, per mulțime activă $\mathcal{A} \Rightarrow$ lege **afină**:

$$u_N^*(x_0) = L_{\mathcal{A}} x_0 + \ell_{\mathcal{A}}$$

- validă pe regiunea $\mathcal{CR}_{\mathcal{A}} = \{x : Z_{\mathcal{A}} x \leq z_{\mathcal{A}}\}$


Limitarea eMPC

- 8729 regiuni $\Rightarrow$ memorie **MB**, căutare lentă
- **neimplementabil** pe ESP32 (SRAM 512 kB)


¹KKT = Karush-Kuhn-Tucker, condiții necesare de optimalitate pentru soluția QP

Rețea neuronală

- **Compoziție:** straturi liniare ($Wx + b$)
- **Activare:** neliniară **ReLU** ($g(p) = \max\{p, 0\}$)
- **Rezultat:** funcție **Afină pe Porțiuni (PWA)**
- **Echivalență:** structură asemănătoare cu legea de control **eMPC**



Arhitectura propusă: $\mathcal{N}(8, 30)$



- **Cost online redus:** evaluare directă (operații algebrice simple)
- **Performanță:** fără căutare prin regiuni

RPI și mRPI

Sistem: $x(k+1) = Ax(k) + w(k)$, $w(k) \in \mathcal{W}$

- **$\mathcal{X}$ RPI**: $x(0) \in \mathcal{X}$, $w(k) \in \mathcal{W} \Rightarrow x(k) \in \mathcal{X}$, $\forall k \geq 0$.
- **mRPI** Ω_∞ : cel mai mic set RPI

$$\Omega_\infty = \lim_{k \rightarrow \infty} \bigoplus_{l=0}^k A^l \mathcal{W}$$

- condiție de invarianță: $\Omega_\infty = A\Omega_\infty \oplus \mathcal{W}$
- $\Rightarrow$ stabilizare, indiferent de perturbații

Aproximare exterioară ε -mRPI

- sumă Minkowski infinită $\rightarrow$ aproximare exterioară

$$\mathcal{Z} = \frac{1}{1-\alpha} \bigoplus_{i=0}^{s-1} A_K^i \mathcal{W}$$

- $\alpha \in (0, 1)$, s : astfel încât $A_K^s \mathcal{W} \subseteq \alpha \mathcal{W}$

Legea de control

- $u_k = \bar{u}_k + K(x_k - \bar{x}_k)$, $A_K = A + BK$ – Schur
- constrângeri nominale: $\bar{\mathcal{X}} = \mathcal{X} \ominus \mathcal{Z}$, $\bar{\mathcal{U}} = \mathcal{U} \ominus K\mathcal{Z}$

Stabilitate

- fezabilitate: $x_k \in \bar{\mathcal{X}}_N \oplus \mathcal{Z}$
- convergență către **mRPI** $\mathcal{Z}$ (nu origine — perturbații aditive mărginite)

Zonotopul

- poliedre: costisitoare la nr. mare de fațete $\rightarrow$ preferăm zonotopi

- definit prin centru c + generatori

$$G = [g_1, \dots, g_p]:$$

$$\mathcal{Z} = \left\{ c + \sum_{i=1}^p \alpha_i g_i \mid \alpha_i \in [-1, 1] \right\}$$

- avantaj: sumă Minkowski și transformare liniară = concatenări/produse de matrice

Algoritmul pentru calculul mRPI

Intrare: $A_K, w_{\text{bound}}, \alpha_{\text{target}}$

① $s \leftarrow 0, \alpha \leftarrow \infty$

② **cât timp** $\alpha > \alpha_{\text{target}}$:

• $s \leftarrow s + 1$

• $\alpha \leftarrow \max_i (|A_K^s| w_{\text{bound}})_i / (w_{\text{bound}})_i$

③ Generatori: $G_W \leftarrow \text{diag}(w_{\text{bound}})$

④ $G_{\mathcal{Z}} \leftarrow \frac{1}{1-\alpha} [G_W, A_K G_W, \dots, A_K^{s-1} G_W]$

⑤ $\mathcal{Z} \leftarrow$ poliedrul dat de funcția suport a lui $G_{\mathcal{Z}}$

Ieșire: $\mathcal{Z}, \alpha, s$

Aproximarea ε -mRPI

$$\mathcal{Z}_s \subseteq \mathcal{Z}_\infty \subseteq \frac{1}{1-\alpha} \mathcal{Z}_s,$$

Interpretare

- pas 1: caută α optim $\rightarrow$ eroare de trunchiere $< 1\%$
- pas 2: construiește $\mathcal{Z}$ prin propagarea $\mathcal{W}$ în A_K

Antrenarea Rețelei: Arhitectură și Date de Antrenament


Generarea datelor: $u^{(i)} = u_{\text{eMPC}}(\bar{x}^{(i)})$

- **Tip 1 — Uniform global:** $x \sim \mathcal{U}(x_{\min}, x_{\max})$
- **Tip 2 — Vecinătatea originii:** legea eMPC variază rapid
- **Tip 3 — Stări extreme:** liniarizarea începe să fie incorectă
- **Tip 4 — În interiorul $\bar{\mathcal{X}} = \mathcal{X} \ominus \mathcal{Z}$:** reduce eroarea și tubul

Pre-antrenare (MSE + ADAM)

$$\theta^* = \arg \min_{\theta} \frac{1}{n_{\text{tr}}} \sum_{i=1}^{n_{\text{tr}}} \|\mathcal{N}(x_{\text{tr},i}; \theta, M, L) - u_{\text{tr},i}\|^2$$

- ADAM, rată variabilă convergența rapidă, 750 epoci
- convergență rapidă $\rightarrow$ rafinare fină, fără oscilații



De ce $\mathcal{N}(8, 30)$?

- $\mathcal{N}(6, 12)$: $\varepsilon_{\max}$ insuficient de mic
- $\mathcal{N}(16, 100)$, $\mathcal{N}(20, 128)$: depășesc SRAM ESP32 (512 kB), fără beneficii
- $\Rightarrow \mathcal{N}(8, 30)$ – **compromisul optim**

Motivație


Pentru un tub $\mathcal{Z}_{NN}$ compact, trebuie minimizată **și** eroarea cea mai nefavorabilă, nu doar media:

$$\varepsilon_{\max} = \max_i |u^{(i)} - u_{NN}(\bar{x}^{(i)})|$$

Algoritmul 3.2 — Re-antrenare (fine-tuning)

Intrare: $\varepsilon_{\text{target}}=0.2$, MAX_ROUNDS=20, rată $=10^{-5}$

- ➊ pentru fiecare rundă: calculează
 $\varepsilon_k = |u_{\text{eMPC}}(\bar{x}_k) - \hat{u}(\bar{x}_k)|$, $\varepsilon_{\max} \leftarrow \max_k \varepsilon_k$
- ➋ dacă $\varepsilon_{\max} < \varepsilon_{\text{target}}$: **stop**
- ➌ $\mathcal{I}_{\text{hard}} \leftarrow \{k \mid \varepsilon_k > \varepsilon_{\text{target}}\}$
- ➍ mini-set = $5 \times \mathcal{I}_{\text{hard}} + 20\%$ date din pre-antrenare;
fine-tune (ADAM, 200 epoci, rată redusă)
- ➎ salvează *best_net* dacă $\varepsilon_{\max}$ scade



Rezultat

- eroare maximă: $\approx 1.35 \rightarrow \varepsilon_{\max} \approx 0.1582$
- eroarea medie $\varepsilon_{\text{mean}}$ — aproape de zero pe tot parcursul

Eroarea totală

$$e(k+1) = A_K e(k) + w_k + B \varepsilon_k = A_K e(k) + d_k$$

- $d_k = w_k + B \varepsilon_k$ mărginit de $d_{\text{bound}} = w_{\text{bound}} + |B| \varepsilon_{\text{max}}$
- $\mathcal{Z}_{NN}$: același **Algoritm mRPI**, cu d_{bound} ca perturbare aditivă

Condiția de invarianță pe funcție suport


- funcție suport: $h_{\mathcal{Z}}(d) = \|G^T d\|_1$
- incluziune $A_K \mathcal{Z}_{NN} \oplus \mathcal{D} \subseteq \mathcal{Z}_{NN}$:

$$\|G^T A_K \mathcal{Z}_{NN} d\|_1 + \|G^T \mathcal{D} d\|_1 \leq \|G^T \mathcal{Z}_{NN} d\|_1$$

- testată pe axele canonice $\{\pm e_i\}$ și coloanele $\{\pm G_j\}$


Constrângeri finale

- $\tilde{\mathcal{X}} = \mathcal{X} \ominus \mathcal{Z}_{NN}$, $\tilde{\mathcal{U}} = \mathcal{U} \ominus K \mathcal{Z}_{NN}$, pentru $\varepsilon_{\text{max}} \approx 0.1582$
- $|x_1| \leq 2.5\text{m}$, $|x_2| \leq 3.0\text{m/s}$, $|x_3| \leq 0.6\text{rad}$, $|x_4| \leq 6.0\text{rad/s}$



Proiecții 2D: $\mathcal{Z}$ (albastru, perturbare w) $\subset \mathcal{Z}_{NN}$ (mov, $+\varepsilon$ aproximare) $\subset A_K \mathcal{Z}_{NN} \oplus \mathcal{D}$ (gri) — incluziune confirmată pe toate cele șase perechi de stări.

Simulare pe Sistemul Liniar





Setup

Simulare : starea inițială $x_0 = [0.5\text{m}, 0, 0.15\text{rad}, 0]^T$, perturbații uniforme mărginite $w(k) \in \mathcal{W}$ cu $N_{\text{sim}} = 200$ pași.

Observații

- x_1 (poziție): suprareglaj ≈ 1.1 m, stabilizare la 3.5s;
- x_3 (unghi): vârf 0.4 rad, convergență la 3s
- stările rămân în ambele tuburi
- Tubul $\mathcal{Z}_{NV}$ depășește $\mathcal{Z}$ cu 60–79% per dimensiune (din $\varepsilon_{max}=0.1582$), fără a încălca limitele fizice.
- sistemul rămâne stabil la perturbațiile totale d_{bound} .

Comanda Aplicată și Eroarea de Aproximare Online





Comanda $u(k)$

Cele trei metode (MPC, eMPC, NN) produc comenzi **similare**.

$$\text{Eroarea } e(k) = |u_{\text{eMPC}}(\bar{x}_k) - u_{\text{NN}}(\bar{x}_k)|$$

Eroarea online rămâne sub $\varepsilon_{\text{max}}^{\text{sim}} \approx 0.0306$, comparativ cu $\varepsilon_{\text{max}}^{\text{train}} = 0.1582$ din antrenament.

Stabilitate Lyapunov și Validare Statistică



Funcția Lyapunov

$V(\bar{x}_k) = \bar{x}_k^T P \bar{x}_k$ măsoară energia sistemului nominal și asigură stabilitatea asimptotică, dacă funcția descrește².

Validare statistică: 1000 stări inițiale aleatoare

- eroare în tub: $\mathcal{Z}$ (eMPC), $\mathcal{Z}_{NN}$ (NN)
- convergență spre echilibru
- zero încălcări (stare/comandă)

² P este soluția stabilizatoare a ecuației Riccati discrete (DARE) pentru perechea (A, B)

Simulare neliniară


- Dinamica neliniară integrată prin Runge–Kutta ord. 4 (CasADi), evaluând sistemul în patru puncte intermediare per pas.

Tubul $\mathcal{Z}$ (liniar)

- Pe x_3, x_4 (unde neliniaritatea e pronunțată), traiectoria depășește $\mathcal{Z}$ când $\sin \theta \approx \theta$ nu mai ține.
- Consecință a linearizării: $\mathcal{Z}$ garantează invarianța **exclusiv** pentru modelul liniar.

Tubul $\mathcal{Z}_{NN}$

- Traiectoriile neliniare depășesc și $\mathcal{Z}_{NN}$ pe x_4 — tubul rămâne neconservativ, păstrând robustețea.
- Erorile de neliniaritate depășesc $\varepsilon_{\max}=0.1582 \Rightarrow$ direcție viitoare: tuburi de robustețe neliniare.



Tabelul 4.1 — Benchmark timing ($N=100$ stări, $T_s=20\text{ms}$)

Metodă	Medie (ms)	WCET (ms)	Std (ms)	Speedup avg	Speedup WCET
MPC implicit	3.8296	15.1258	1.3098	1.0×	1.0×
eMPC explicit	0.1449	1.5134	0.3304	26.4×	10.0×
NN algebric	0.0048	0.0449	0.0041	795.7×	336.9×

Tabelul 4.2 — Comparație de memorie

Metodă	Tipul memoriei	Memorie (kB)	Sursa memoriei	Observație
MPC implicit	Matrice QP online	2.93	H, A_{eq}, A_{ineq}	Solver QP online
eMPC explicit	Regiuni poliedrice	3347.2 (≈ 3.27 MB)	8729 regiuni	64× față de NN
NN algebric	Ponderi rețea	52.27	6691 parametri	Referință


Instalația fizică³

- Cărucior pe șină liniară, acționat de motor pas-cu-pas **NEMA17** prin curea dințată, comandat de driverul **TMC2209** (STEP/DIR);
- Doi encodere optici: poziție cărucior + unghi pendul;
- Vitezele se obțin prin diferențiere numerică + filtru trece-jos (reduce zgomotul senzorilor).

Microcontroler: ESP32 dual-core


- **Nucleul 1:** generează impulsurile STEP pentru motor, în buclă continuă, neafectat de restul codului;
- **Nucleul 2:** bucla de control la $T_s=0.02\text{ s}$ — citește encoderii, estimează $\mathbf{x}_k$, evaluează rețeaua și trimite viteza de referință către Nucleul 1.

Simulare NN controller (+ perturbatie w_k)




Simularea rețelei $\mathcal{N}(8, 30)$ în neliniar cu perturbație aditivă w_k

³Instalație fizică preluată din A. Vener, „Synthesis of a Predictive Control Law for a Nonlinear System”, lucrare de licență, UPB, 2024



Comanda $u_{NN}(k)$

- Pendul de laborator simplificat — nu reproduce fidel un sistem industrial.
- Comanda comută rapid între ± 8 N — caracter **oscilant**, din cauza **aproximării** legii de control și a necesității stabilizării rapide a sistemului neliniar.



Stările sistemului

- θ oscilează în jurul lui 0 (± 0.05 – 0.1 rad); $\dot{\theta}$ oscilează constant ± 1.5 rad/s, fără atenuare.
- Poziția căruciorului oscilează lent între -0.2 și $+0.11$ m.

Rezultatele obținute

- 1 **eMPC explicit** (8729 regiuni, cost terminal LQR/DARE) rezolvat offline cu MPT3: **3.27 MB**, căutare lentă a regiunii.
- 2 **Rețea ReLU** $\mathcal{N}(8, 30)$ antrenată + fine-tuned ($\varepsilon_{\max} \approx 0.1582$): **52.27 kB** (−98.4%), **795.7×** mai rapidă în medie.
- 3 **Tub robust** $\mathcal{Z}_{NN}$ (cu zonotopi) garantează invarianța față de perturbații și eroarea NN: $d_{\text{bound}} = w_{\text{bound}} + |B|\varepsilon_{\max}$.
- 4 **Validare**: 100% menținere în tub și convergență Lyapunov pe 1000 traiectorii aleatoare; confirmare pe sistemul neliniar (RK4) și pe instalația fizică (ESP32).

Limitări

- Nicio garanție Lyapunov **formală** pentru rețeaua NN (set terminal $\mathcal{X}_f^{NN}$ doar aproximat prin P_{DARE});
- Tubul $\mathcal{Z}$ garantează invarianța doar pentru modelul **liniarizat**;;
- Comanda fizică u_{NN} rămâne oscilantă în regim de stabilizare.

Direcții Viitoare

- Funcție cost de antrenare orientată spre minimizarea directă a $\varepsilon_{\max}$ (penalizare erori mari);
- Extinderea metodei la sistemul complet neliniar (NMPC, tuburi neliniare);
- Determinarea unui set terminal invariant $\mathcal{X}_f^{NN}$ dedicat rețelei, pentru o garanție Lyapunov formală.

- ❶ J.M. Maciejowski. *Predictive Control with Constraints*. Harlow, UK: Prentice Hall, 2002.
- ❷ Ș.S. Mihai, F. Stoican și B.D. Ciubotaru. „Computing the Explicit MPC Solution Using the Hasse Diagram of the Lifted Feasible Domain”. În: *Proc. ECC 2023*. Bucharest: IEEE, 2023, pag. 1–7. DOI: [10.23919/ECC57647.2023.10178222](https://doi.org/10.23919/ECC57647.2023.10178222).
- ❸ M. Schulze Darup. „Exact Representation of Piecewise Affine Functions via Neural Networks”. În: *Proc. ECC 2020*. Saint Petersburg: IEEE, 2020, pag. 1073–1078. DOI: [10.23919/ECC51009.2020.9143983](https://doi.org/10.23919/ECC51009.2020.9143983).
- ❹ D.Q. Mayne, M.M. Seron și S.V. Raković. „Robust model predictive control of constrained linear systems with bounded disturbances”. În: *Automatica* 41.2 (2005), pag. 219–224. DOI: [10.1016/j.automatica.2004.08.019](https://doi.org/10.1016/j.automatica.2004.08.019).
- ❺ Sorin Olaru. „Predictive Control”. Lecture notes, Master ATSI, CentraleSupélec. 2025.
- ❻ Andrei Vener. „Synthesis of a Predictive Control Law for a Nonlinear System”. Bachelor’s thesis. Bucharest: Faculty of Automatic Control and Computers, UPB, iul. 2024.
- ❼ B. Karg și S. Lucia. „Efficient Representation and Approximation of Model Predictive Control Laws via Deep Learning”. În: *IEEE Transactions on Cybernetics* 50.9 (2020), pag. 3866–3878. DOI: [10.1109/TCYB.2020.2999556](https://doi.org/10.1109/TCYB.2020.2999556).
- ❽ S.V. Raković și alții. „Invariant Approximations of the Minimal Robust Positively Invariant Set”. În: *IEEE Transactions on Automatic Control* 50.3 (2005), pag. 406–410. DOI: [10.1109/TAC.2005.843854](https://doi.org/10.1109/TAC.2005.843854).
- ❾ A. Girard. „Reachability of Uncertain Linear Systems Using Zonotopes”. În: *HSCC 2005*. Vol. 3414. Springer, 2005, pag. 291–305. DOI: [10.1007/978-3-540-31954-2_19](https://doi.org/10.1007/978-3-540-31954-2_19).
- ❿ F. Stoican, C. Oară și M. Hovd. „RPI Approximations of the mRPI Set Characterizing Linear Dynamics with Zonotopic Disturbances”. În: *Developments in Model-Based Optimization and Control*. Vol. 464. Springer, 2015, pag. 329–348. DOI: [10.1007/978-3-319-26687-9_17](https://doi.org/10.1007/978-3-319-26687-9_17).
- ⓫ Diederik P. Kingma și Jimmy Ba. „Adam: A method for stochastic optimization”. În: *arXiv preprint arXiv:1412.6980* (2014).
- ⓬ Franco Blanchini și Stefano Miani. *Set-Theoretic Methods in Control*. Springer, 2015. ISBN: 978-3-319-17932-2. DOI: [10.1007/978-3-319-17933-9](https://doi.org/10.1007/978-3-319-17933-9).
- ⓭ J.A.E. Andersson și alții. „CasADi – A software framework for nonlinear optimization and optimal control”. În: *Mathematical Programming Computation* 11.1 (2019), pag. 1–36. DOI: [10.1007/s12532-018-0139-4](https://doi.org/10.1007/s12532-018-0139-4).